

Metodología de pronóstico multivariado con aprendizaje autónomo, integración en la nube y reportes automatizados

Luis D. Chavarría y Juan M. Cogollo

Facultad de Minas, Dpto. Ingeniería de la Organización, Universidad Nacional de Colombia.

ldchavarriam@unal.edu.co; jmcogollof@unal.edu.co

Resumen

La estimación correcta de la demanda desagregada para múltiples productos es fundamental para el buen funcionamiento de la mayoría de los modelos de gestión industrial y financiera (MPS, MRP, EOQ, flujos de caja, entre otros). El análisis de series de tiempo es una de las herramientas más utilizadas en este campo y tiene como objetivo hacer predicciones basándose en los datos del pasado. Este tipo de análisis requiere alto rigor matemático-estadístico para ser confiable; por lo que no es escalable de manera factible a n productos por su alto costo, por lo que, en ocasiones, las empresas prefieren utilizar métodos cualitativos o empíricos. El análisis multivariado de series temporales asume como estructura de datos un formato en el que cada fila representa un punto temporal y cada columna contiene una serie de tiempo única (Wang, Cook, & Hyndman, 2019); esto implica que las columnas deben ser de un tipo homogéneo y de la misma longitud, lo cual es un requisito estricto. Generalmente, los datos recolectados por las empresas no cumplen estas dos condiciones por lo que se presentan inconvenientes al momento de realizar pronósticos con las técnicas tradicionales. Por ello, en este trabajo se desarrolla y aplica una metodología que supera estos inconvenientes y se adapta de mejor manera a las estructuras de datos de las empresas.

Con la utilización de métodos y software para pronósticos en el estado del arte, como el paquete en desarrollo *'fable'* (Hyndman, O'Hara-Wild, & Wang, 2019) de **R** se construyó un programa computacional de licencia libre que utiliza técnicas de *Machine Learning* entrenándose con los datos históricos de n series de tiempo. Este software entrega los pronósticos mediante un reporte que incluye las gráficas para cada producto como se puede ver en la Figura 1; adicionalmente, se presentan las respectivas medidas de ajuste expuestas (*Akaike's Information Criterion* – AIC, *Bayesian Information Criterion* – BIC) de manera reducida en la Tabla 1 utilizando el paquete *'broom'* (Robinson & Hayes, 2019).

El programa soporta predicciones mediante los modelos del paquete *'fable'*, a la fecha: AR(p), MA(q), ARMA(p,q), ARIMA(p,d,q), Holt, Winters, Holt-Winters, SARIMA(p,d,q)(P,D,Q)[s], *State Space Models*, redes neuronales para series de tiempo, caminatas aleatorias, modelos globales con variables indicadoras y regresores exógenos con términos de Fourier.

El desarrollo, adicionalmente, le proporciona al usuario la posibilidad de tomar los datos directamente desde la nube, ofreciendo la posibilidad de integrar sus métodos actuales, extrayendo la información directamente desde la API de Google Drive y consecuentemente, de sus hojas de cálculo compartidas en tiempo real.

Esto permite además de integración de la cadena de suministro, una disminución en los retardos de información y de material.

Se realizó la implementación en una empresa local de fabricación de aceites y lubricantes para vehículos, con resultados positivos para 250 SKUs (*Stock Keeping Units*); el tiempo promedio

de corrida del programa y generación automática de los reportes para 3 modelos en cada referencia fue de 3 minutos; las medidas de ajuste y pronóstico fueron evaluadas para 10 SKUs seleccionados mediante muestreo aleatorio sin diferencias significativas con respecto a los resultados mediante métodos tradicionales de análisis de series de tiempo.

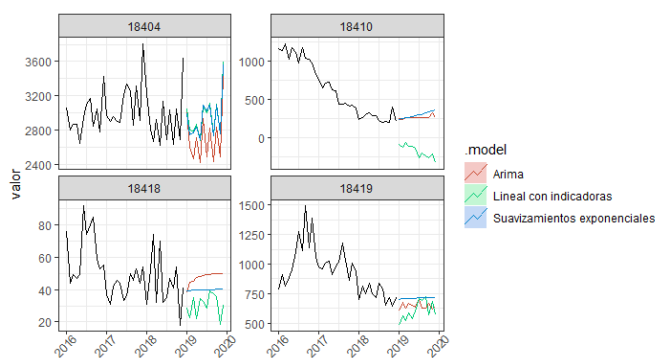


Figura 1. Series y pronósticos para 4 SKUs.

Tabla 1. Medidas de ajuste de los modelos para el SKU 18404.

Modelo ajustado	AIC	BIC
Global con indicadoras	478,572	500,741
Arima	312,243	314,514
Suavizamientos exponenciales	99,384	123,137

Referencias

Hyndman, R., O'Hara-Wild, M., & Wang, E. (2019). Fable R Package. Retrieved from

<https://fable.tidyverts.org/index.html>

Robinson, D., & Hayes, A. (2019). broom: Convert Statistical Analysis Objects into Tidy Tibbles. CRAN. Retrieved from

<https://cran.r-project.org/package=broom>

Wang, E., Cook, D., & Hyndman, R. J. (2019). A new tidy data structure to support exploration and modeling of temporal data, (February). Retrieved from <http://arxiv.org/abs/1901.10257>